

Aprendizaje Perezoso de Reglas Bayesianas

Proyecto Final - Aprendizaje Automático

Alejandro Cárdenas Barranco, Mónica Calzado Granados, Jesús
García León, Álvaro Rodríguez Gallardo, Juan Manuel
Rodríguez Gómez

Universidad de Granada

Curso 2023/2024



UNIVERSIDAD
DE GRANADA

① Fundamentos Teóricos

② Algoritmo LBR

③ Experimentación

④ Resultados

⑤ Conclusiones

1 Fundamentos Teóricos

2 Algoritmo LBR

3 Experimentación

4 Resultados

5 Conclusiones

Naive Bayes

Problema de clasificación con n atributos $V = \{v_1, v_2, \dots, v_n\}$ y k clases $C_i \in \Omega = \{C_1, C_2, \dots, C_k\}$.

Naive Bayes

Problema de clasificación con n atributos $V = \{v_1, v_2, \dots, v_n\}$ y k clases $C_i \in \Omega = \{C_1, C_2, \dots, C_k\}$.

- **Teorema de Bayes** aplicado a clasificación:

$$P(C_i|V) = \frac{P(C_i) \cdot P(V|C_i)}{P(V)} \quad (1)$$

Naive Bayes

Problema de clasificación con n atributos $V = \{v_1, v_2, \dots, v_n\}$ y k clases $C_i \in \Omega = \{C_1, C_2, \dots, C_k\}$.

- **Teorema de Bayes** aplicado a clasificación:

$$P(C_i|V) = \frac{P(C_i) \cdot P(V|C_i)}{P(V)} \quad (1)$$

- **Hipótesis MAP:**

$$C_{\text{MAP}} = \arg \max_{C_i \in \Omega} P(C_i | V)$$

Naive Bayes

Problema de clasificación con n atributos $V = \{v_1, v_2, \dots, v_n\}$ y k clases $C_i \in \Omega = \{C_1, C_2, \dots, C_k\}$.

- **Teorema de Bayes** aplicado a clasificación:

$$P(C_i|V) = \frac{P(C_i) \cdot P(V|C_i)}{P(V)} \quad (1)$$

- **Hipótesis MAP:**

$$C_{\text{MAP}} = \arg \max_{C_i \in \Omega} P(C_i | V)$$

- **Problema:** Calcular $P(V|C_i)$ es computacionalmente insostenible.

Naive Bayes

Problema de clasificación con n atributos $V = \{v_1, v_2, \dots, v_n\}$ y k clases $C_i \in \Omega = \{C_1, C_2, \dots, C_k\}$.

- **Solución:** Asumir independencia.

$$P(V|C_i) = \prod_{v_j \in V} P(v_j|C_i)$$

Naive Bayes

Problema de clasificación con n atributos $V = \{v_1, v_2, \dots, v_n\}$ y k clases $C_i \in \Omega = \{C_1, C_2, \dots, C_k\}$.

- **Solución:** Asumir independencia.

$$P(V|C_i) = \prod_{v_j \in V} P(v_j|C_i)$$

- **Hipótesis MAP:**

$$\begin{aligned} C_{\text{MAP}} &= \arg \max_{C_i \in \Omega} P(C_i | V) \\ &= \arg \max_{C_i \in \Omega} P(C_i) \prod_{j=1}^n P(x_j | C_i) \end{aligned} \quad (2)$$

Algoritmo de Reglas Bayesianas Perezosas (LBR)

Basado en dos algoritmos:

Algoritmo de Reglas Bayesianas Perezosas (LBR)

Basado en dos algoritmos:

- **NBTREE** (*Naive Bayesian Tree*):
 - Árbol de decisión.
 - Clasificador Naive Bayes en cada hoja.
 - Gran coste computacional.

Algoritmo de Reglas Bayesianas Perezosas (LBR)

Basado en dos algoritmos:

- **NBTREE** (*Naive Bayesian Tree*):
 - Árbol de decisión.
 - Clasificador Naive Bayes en cada hoja.
 - Gran coste computacional.
- **LAZYDT** (*Lazy Decision Tree*):
 - Enfoque de *lazy learning*.
 - Construye una regla de decisión para cada nuevo ejemplo.
 - Regla bayesiana: Antecedente y consecuente.
 - Flexibilidad y escalabilidad.

Algoritmo de Reglas Bayesianas Perezosas (LBR)

- Genera una **regla bayesiana** para cada instancia.
 - **Antecedente:** Pares de atributos-valores.
 - **Consecuente:** Clasificador Naive Bayes local.

Algoritmo de Reglas Bayesianas Perezosas (LBR)

- Genera una **regla bayesiana** para cada instancia.
 - **Antecedente:** Pares de atributos-valores.
 - **Consecuente:** Clasificador Naive Bayes local.
- **Ventajas:**
 - Adaptabilidad.
 - Eficiencia en la estimación.
 - Manejo eficiente de los atributos.

Algoritmo de Reglas Bayesianas Perezosas (LBR)

- Genera una **regla bayesiana** para cada instancia.
 - **Antecedente:** Pares de atributos-valores.
 - **Consecuente:** Clasificador Naive Bayes local.
- **Ventajas:**
 - Adaptabilidad.
 - Eficiencia en la estimación.
 - Manejo eficiente de los atributos.
- **Limitaciones:**
 - Grandes requerimientos de memoria.

① Fundamentos Teóricos

② Algoritmo LBR

③ Experimentación

④ Resultados

⑤ Conclusiones

Funcionamiento (Pseudocódigo)

Input:

Att : Un conjunto de atributos.

$D_{entrenamiento}$: Un conjunto de ejemplos de entrenamiento descritos con Att y sus etiquetas.

E_{test} : Un ejemplo de prueba descrito usando Att .

Output: Clase predicha para E_{test} .

- 1 $LocalNB \leftarrow$ Clasificador NB entrenado usando Att en $D_{entrenamiento}$
- 2 $Errores \leftarrow$ errores de $LocalNB$ estimados usando Leave-One-Out en $D_{entrenamiento}$

Funcionamiento (Pseudocódigo)

Input:

Att : Un conjunto de atributos.

$D_{entrenamiento}$: Un conjunto de ejemplos de entrenamiento descritos con Att y sus etiquetas.

E_{test} : Un ejemplo de prueba descrito usando Att .

Output: Clase predicha para E_{test} .

- 1 $LocalNB \leftarrow$ Clasificador NB entrenado usando Att en $D_{entrenamiento}$
- 2 $Errores \leftarrow$ errores de $LocalNB$ estimados usando Leave-One-Out en $D_{entrenamiento}$

Funcionamiento (Pseudocódigo)

```
4 while true do
5    $TempErrors_{mejor} \leftarrow$  el número de ejemplos en  $D_{entrenamiento} + 1$ 
6   for cada atributo  $A$  en  $Att$  cuyo valor  $v_A$  en  $E_{test}$  no sea nulo do
7      $D_{subset} \leftarrow$  ejemplos en  $D_{entrenamiento}$  con  $A = v_A$ 
8      $TempNB \leftarrow$  clasificador NB entrenado usando  $Att - \{A\}$  en
        $D_{subset}$ 
9      $TempErrors \leftarrow$  errores de  $TempNB$  estimados usando
       Leave-One-Out en  $D_{subset} +$  errores de  $Errores$  para ejemplos en
        $D_{entrenamiento} - D_{subset}$ 
10    if ( $TempErrors < TempErrors_{mejor}$  AND  $TempErrors < Errores$ )
11      then
12         $TempNB_{mejor} \leftarrow TempNB$ 
13         $TempErrors_{mejor} \leftarrow TempErrors$ 
14         $A_{mejor} \leftarrow A$ 
15    end
  end
```

Funcionamiento (Pseudocódigo)

```
4 while true do
5    $TempErrors_{mejor} \leftarrow$  el número de ejemplos en  $D_{entrenamiento} + 1$ 
6   for cada atributo  $A$  en  $Att$  cuyo valor  $v_A$  en  $E_{test}$  no sea nulo do
7      $D_{subset} \leftarrow$  ejemplos en  $D_{entrenamiento}$  con  $A = v_A$ 
8      $TempNB \leftarrow$  clasificador NB entrenado usando  $Att - \{A\}$  en
        $D_{subset}$ 
9      $TempErrors \leftarrow$  errores de  $TempNB$  estimados usando
       Leave-One-Out en  $D_{subset} +$  errores de  $Errores$  para ejemplos en
        $D_{entrenamiento} - D_{subset}$ 
10    if ( $TempErrors < TempErrors_{mejor}$  AND  $TempErrors < Errores$ )
11      then
12         $TempNB_{mejor} \leftarrow TempNB$ 
13         $TempErrors_{mejor} \leftarrow TempErrors$ 
14         $A_{mejor} \leftarrow A$ 
15    end
  end
```

Funcionamiento (Pseudocódigo)

```
4 while true do
5    $TempErrors_{mejor} \leftarrow$  el número de ejemplos en  $D_{entrenamiento} + 1$ 
6   for cada atributo  $A$  en  $Att$  cuyo valor  $v_A$  en  $E_{test}$  no sea nulo do
7      $D_{subset} \leftarrow$  ejemplos en  $D_{entrenamiento}$  con  $A = v_A$ 
8      $TempNB \leftarrow$  clasificador NB entrenado usando  $Att - \{A\}$  en
        $D_{subset}$ 
9      $TempErrors \leftarrow$  errores de  $TempNB$  estimados usando
       Leave-One-Out en  $D_{subset} +$  errores de  $Errores$  para ejemplos en
        $D_{entrenamiento} - D_{subset}$ 
10    if ( $TempErrors < TempErrors_{mejor}$  AND  $TempErrors < Errores$ )
11      then
12         $TempNB_{mejor} \leftarrow TempNB$ 
13         $TempErrors_{mejor} \leftarrow TempErrors$ 
14         $A_{mejor} \leftarrow A$ 
15    end
  end
```

Funcionamiento (Pseudocódigo)

```
4 while true do
5    $TempErrors_{mejor} \leftarrow$  el número de ejemplos en  $D_{entrenamiento} + 1$ 
6   for cada atributo  $A$  en  $Att$  cuyo valor  $v_A$  en  $E_{test}$  no sea nulo do
7      $D_{subset} \leftarrow$  ejemplos en  $D_{entrenamiento}$  con  $A = v_A$ 
8      $TempNB \leftarrow$  clasificador NB entrenado usando  $Att - \{A\}$  en
        $D_{subset}$ 
9      $TempErrors \leftarrow$  errores de  $TempNB$  estimados usando
       Leave-One-Out en  $D_{subset} +$  errores de  $Errores$  para ejemplos en
        $D_{entrenamiento} - D_{subset}$ 
10    if ( $TempErrors < TempErrors_{mejor}$  AND  $TempErrors < Errores$ )
11      then
12         $TempNB_{mejor} \leftarrow TempNB$ 
13         $TempErrors_{mejor} \leftarrow TempErrors$ 
14         $A_{mejor} \leftarrow A$ 
15    end
end
```

Funcionamiento (Pseudocódigo)

```
4 while true do
5    $TempErrors_{mejor} \leftarrow$  el número de ejemplos en  $D_{entrenamiento} + 1$ 
6   for cada atributo  $A$  en  $Att$  cuyo valor  $v_A$  en  $E_{test}$  no sea nulo do
7      $D_{subset} \leftarrow$  ejemplos en  $D_{entrenamiento}$  con  $A = v_A$ 
8      $TempNB \leftarrow$  clasificador NB entrenado usando  $Att - \{A\}$  en
        $D_{subset}$ 
9      $TempErrors \leftarrow$  errores de  $TempNB$  estimados usando
       Leave-One-Out en  $D_{subset} +$  errores de  $Errores$  para ejemplos en
        $D_{entrenamiento} - D_{subset}$ 
10    if ( $TempErrors < TempErrors_{mejor}$  AND  $TempErrors < Errores$ )
11      then
12         $TempNB_{mejor} \leftarrow TempNB$ 
13         $TempErrors_{mejor} \leftarrow TempErrors$ 
14         $A_{mejor} \leftarrow A$ 
15    end
  end
```

Funcionamiento (Pseudocódigo)

```
16  if se ha encontrado un  $A_{mejor}$  then
17       $LocalNB \leftarrow TempNB_{mejor}$ 
18       $D_{entrenamiento} \leftarrow D_{subset}$  correspondiente a  $A_{mejor}$ 
19       $Att \leftarrow Att - \{A_{mejor}\}$ 
20       $Errores \leftarrow$  errores de  $LocalNB$  estimados usando
        Leave-One-Out en  $D_{entrenamiento}$ 
21  else
22      break
23  end
24 end
25  $Clase \leftarrow LocalNB(E_{test})$ 
26 return Clase
```

Funcionamiento (Pseudocódigo)

```
16  if se ha encontrado un  $A_{mejor}$  then
17     $LocalNB \leftarrow TempNB_{mejor}$ 
18     $D_{entrenamiento} \leftarrow D_{subset}$  correspondiente a  $A_{mejor}$ 
19     $Att \leftarrow Att - \{A_{mejor}\}$ 
20    Errores  $\leftarrow$  errores de  $LocalNB$  estimados usando
      Leave-One-Out en  $D_{entrenamiento}$ 
21  else
22    break
23  end
24 end
25 Clase  $\leftarrow LocalNB(E_{test})$ 
26 return Clase
```

Funcionamiento (Pseudocódigo)

```
16  if se ha encontrado un  $A_{mejor}$  then
17     $LocalNB \leftarrow TempNB_{mejor}$ 
18     $D_{entrenamiento} \leftarrow D_{subset}$  correspondiente a  $A_{mejor}$ 
19     $Att \leftarrow Att - \{A_{mejor}\}$ 
20    Errores  $\leftarrow$  errores de  $LocalNB$  estimados usando
      Leave-One-Out en  $D_{entrenamiento}$ 
21  else
22    break
23  end
24 end
25 Clase  $\leftarrow LocalNB(E_{test})$ 
26 return Clase
```

Funcionamiento (Pseudocódigo)

```
16  if se ha encontrado un  $A_{mejor}$  then
17       $LocalNB \leftarrow TempNB_{mejor}$ 
18       $D_{entrenamiento} \leftarrow D_{subset}$  correspondiente a  $A_{mejor}$ 
19       $Att \leftarrow Att - \{A_{mejor}\}$ 
20      Errores  $\leftarrow$  errores de  $LocalNB$  estimados usando
        Leave-One-Out en  $D_{entrenamiento}$ 
21  else
22      break
23  end
24 end
25 Clase  $\leftarrow LocalNB(E_{test})$ 
26 return Clase
```

1 Fundamentos Teóricos

2 Algoritmo LBR

3 Experimentación

4 Resultados

5 Conclusiones

Metodología

- **Lenguaje de programación:** Python. Scikit-Learn y Seaborn.
- **Entorno:** Google Colab + Google Drive.
- Comparación de LBR con diferentes **algoritmos** clásicos de aprendizaje supervisado.

Metodología

- **Lenguaje de programación:** Python. Scikit-Learn y Seaborn.
- **Entorno:** Google Colab + Google Drive.
- Comparación de LBR con diferentes **algoritmos** clásicos de aprendizaje supervisado.
 - **LBR.**
 - **Random Forest.**
 - **Naive Bayes.**
 - **k-NN.**
 - **XGBoost.**

Datasets Utilizados

- **Iris:** Datos de tres especies de flores de iris. Conjunto equilibrado (50 muestras por clase).
 - **Total de Instancias:** 150.
 - **Número de Características:** 4.
 - **Número de Clases:** 3.

Datasets Utilizados

- **Iris:** Datos de tres especies de flores de iris. Conjunto equilibrado (50 muestras por clase).
 - **Total de Instancias:** 150.
 - **Número de Características:** 4.
 - **Número de Clases:** 3.
- **Wine:** Análisis químico de vinos cultivados en la misma región de Italia pero derivados de tres diferentes cultivares. Conjunto no equilibrado.
 - **Total de Instancias:** 178.
 - **Número de Características:** 13.
 - **Número de Clases:** 3.

Datasets Utilizados

- **Penguins:** Datos sobre tres especies de pingüinos encontrados en las islas Palmer cerca de la Antártida. Conjunto no equilibrado.
 - **Total de Instancias:** 344.
 - **Número de Características:** 7.
 - **Número de Clases:** 3.

Datasets Utilizados

- **Penguins:** Datos sobre tres especies de pingüinos encontrados en las islas Palmer cerca de la Antártida. Conjunto no equilibrado.
 - **Total de Instancias:** 344.
 - **Número de Características:** 7.
 - **Número de Clases:** 3.
- **Tips:** Información sobre las propinas recibidas por los camareros en un restaurante durante un período específico. Orientado tanto a análisis de regresión como de clasificación.
 - **Total de Instancias:** 244.
 - **Número de Características:** 7.
 - **Número de Clases:** 2.

① Fundamentos Teóricos


② Algoritmo LBR

③ Experimentación


④ Resultados

⑤ Conclusiones

Métrica: Validation Accuracy




Métrica: Precision



Métrica: Recall



Métrica: F1-Score



① Fundamentos Teóricos

② Algoritmo LBR

③ Experimentación

④ Resultados

⑤ Conclusiones

Conclusiones Principales

- **Implementación y eficacia de LBR.**

Conclusiones Principales

- **Implementación y eficacia de LBR.**
- **Capacidad de adaptación a especificidades de instancias.**

Conclusiones Principales

- **Implementación y eficacia de LBR.**
- **Capacidad de adaptación a especificidades de instancias.**
- **Competitividad frente a modelos clásicos.**

Conclusiones Principales

- **Implementación y eficacia de LBR.**
- **Capacidad de adaptación a especificidades de instancias.**
- **Competitividad frente a modelos clásicos.**
- **Manejo efectivo de dependencias entre atributos.**

Conclusiones Principales

- **Implementación y eficacia de LBR.**
- **Capacidad de adaptación a especificidades de instancias.**
- **Competitividad frente a modelos clásicos.**
- **Manejo efectivo de dependencias entre atributos.**
- **Buenos resultados en diversos dominios.**

Conclusiones Principales

- **Implementación y eficacia de LBR.**
- **Capacidad de adaptación a especificidades de instancias.**
- **Competitividad frente a modelos clásicos.**
- **Manejo efectivo de dependencias entre atributos.**
- **Buenos resultados en diversos dominios.**
- **Limitaciones en grandes conjuntos de datos.**

Trabajos Futuros

- **Optimización y escalabilidad.**

Trabajos Futuros

- **Optimización y escalabilidad.**
- **Extensión a atributos numéricos.**

Trabajos Futuros

- **Optimización y escalabilidad.**
- **Extensión a atributos numéricos.**
- **Aplicaciones en nuevos dominios.**

Trabajos Futuros

- **Optimización y escalabilidad.**
- **Extensión a atributos numéricos.**
- **Aplicaciones en nuevos dominios.**
- **Integración con técnicas de aprendizaje profundo.**

Trabajos Futuros

- **Optimización y escalabilidad.**
- **Extensión a atributos numéricos.**
- **Aplicaciones en nuevos dominios.**
- **Integración con técnicas de aprendizaje profundo.**
- **Mejora en el manejo de datos faltantes y ruidosos.**

Trabajos Futuros

- **Optimización y escalabilidad.**
- **Extensión a atributos numéricos.**
- **Aplicaciones en nuevos dominios.**
- **Integración con técnicas de aprendizaje profundo.**
- **Mejora en el manejo de datos faltantes y ruidosos.**
- **Desarrollo de frameworks de evaluación más rigurosos.**

Fin de la Presentación

Gracias por su atención.